

1. Matriz de Confusión + métricas

• Ejercicio 1: Construcción básica

- Construir matriz de confusión

	Predicción Positiva	Predicción Negativa
Real Positivo	TP = 50	FN = 5
Real Negativo	FP = 10	TN = 35

- Cálculos

• Accuracy

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{50 + 35}{50 + 35 + 10 + 5} = \frac{85}{100} = 0.85$$

$$\text{accuracy} = 0.85 \text{ ó } 85\%$$

• Precision

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{50}{50 + 10} = \frac{50}{60} = 0.83$$

$$\text{Precision} = 0.83 \text{ ó } 83\%$$

• Recall

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{50}{50 + 5} = \frac{50}{55} = 0.91$$

$$\text{Recall} = 0.91 \text{ ó } 91\%$$

• F1-Score

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \cdot \frac{(0.83)(0.91)}{(0.83) + (0.91)} = 2 \cdot \frac{0.7553}{1.74} = 2 \cdot 0.4340$$

$$= 0.8681$$

$$F1 = 0.8681 \text{ ó } 86.81\%$$

- Discusión: ¿Qué métrica es más importante si es detección de enfermedad? Recall pues es quien mide cuantos enfermos reales detectas correctamente, un FN significa que alguien enfermo no fu detectado y esto es peligroso. Pues no recibe tratamiento y así es mejor dejar pasar un FP a dejar pasar un enfermo.

2. Métricas con desbalance de clases

• Ejercicio 2: Dataset médico: detección de enfermedad (solo 5% positivos)

	Pred: Si	Pred: No
Real: Si	8	2
Real: No	90	900

- ¿Accuracy es una buena métrica aquí?

$$\text{Accuracy} = \frac{TP + TN}{\text{Total}} = \frac{8 + 900}{1000} = 0.908 \text{ ó } 90.8\%$$

No es buena métrica porque el dataset está desbalanceado (solo 5% positivos) y el modelo puede acertar muchos negativos y aún así fallar en lo importante.

- Calcular Recall y Precision

$$\text{recall} = \frac{TP}{TP + FN} = \frac{8}{8 + 2} = \frac{8}{10} = 0.8 \text{ ó } 80\%$$

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{8}{8 + 90} = \frac{8}{98} = 0.08163 \text{ ó } 8.163\%$$

¿Qué métrica Priorizarias y Por qué?

Prioritaria Recall por que debido a que es un problema médico es mas importante detectar a los enfermos y un falso negativo puede ser grave por no atenderlo y dejar que se propague la enfermedad.

- ¿Es un buen modelo? ¿Por qué?

No, debido a que a pesar de que el recall es decente la precisión es muy baja y nos da muchos falsos positivos y detectamos a mucha gente sana como enferma y genera alarmas falsas que pierden tiempo ante una real..

3: Error en regresión (MSE vs MAE)

• Ejercicio 3: Predicciones de precios:

Real	Pred
100	90
200	210
300	1000

- MAE

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| = \frac{|100-90| + |200-210| + |300-1000|}{3}$$
$$= \frac{10 + 10 + 700}{3} = \frac{720}{3} = 240$$

MAE = 240

- MSE

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{(100-90)^2 + (200-210)^2 + (300-1000)^2}{3}$$
$$= \frac{(10)^2 + (-10)^2 + (-700)^2}{3} = \frac{100 + 100 + 490000}{3} = \frac{490200}{3} = 163400$$

MSE = 163400

- ¿Cuál penaliza más errores grandes?

El MSE porque eleva al cuadrado los errores algo grande como (700) se vuelve 490000 mientras el MAE solo suma diferencias absolutas dando menos impacto.

4: Regresión lineal.

• Ejercicio 4: Interpretación de coeficientes

Modelo = $y = 5 + 2x_1 - 3x_2$

- Interpreta cada coeficiente

• (5) = es el valor de y cuando $x_1 = 0$ y $x_2 = 0$

• Coeficiente de x_1 (2) = Si x_1 aumenta en 1, y aumenta en 2, manteniendo x_2 constante

• Coeficiente de x_2 (-3) = Si x_2 aumenta en 1, y disminuye en 3, manteniendo x_1 constante

- ¿Que pasa si x_2 aumenta?

y disminuye pues por cada aumento de x_2 , y baja 3 unidades

5: Regresión Logística (Interpretación)

Ejercicio 5. Modelo:

$$P(y=1|x) = \frac{1}{1+e^{-(2x+4)}}$$

- ¿Qué pasa cuando $x=2$?

$$2x - 4 = 2(2) - 4 = 0$$

$$P(y=1) = \frac{1}{1+e^0} = \frac{1}{2} = 0.5$$

Probabilidad es 0.5 o 50%

- ¿Cuál es el umbral de decisión?

El típico es 0.5

- Si $p \geq 0.5 \rightarrow$ clase 1

- Si $p < 0.5 \rightarrow$ Clase 0

En este modelo, el punto de decisión ocurre cuando

$$(2x - 4) = 0 \Rightarrow x = 2$$

- ¿Qué significa el coeficiente 2?

Es el peso de x indica cuánto influye x en la probabilidad, al aumentar x , aumenta la probabilidad de $y=1$ y entre más grande el valor, más fuerte es el efecto.

6: Support Vector Machines (SVM)


Ejercicio 6: Margen máximo

Dado un plano con puntos separables:

clase +1: (2,2), (3,3)

clase -1: (0,0), (1,1)

- Dibuja los puntos



- Proponer una recta separadora

$$y = x - 1.5$$

pues queda entre los 2 grupos

arriba $\rightarrow$ clase +1

abajo $\rightarrow$ clase -1

- Identificar soporte vectorial (intuitivo)

(1,1) de la clase -1

(2,2) de la clase +1

(tocon el margen) y son los más cercanos a la recta separadora

• Ejercicio 7: SUM con kernel
Un dataset NO es linealmente separable.

- ¿Por qué falla un SUM lineal?

Porque intenta separar los datos con una línea recta (o plano) y si los datos están mezclados de forma no lineal (círculos), no existe una línea que los separe correctamente.

- ¿Por qué usan un kernel?

Porque el kernel transforma los datos a un espacio de mayor dimensión y ahí los datos sí se pueden separar con una línea (o plano), es como reacomodar los datos para que sean separables.

- En un ejemplo con datos en forma de círculo, explica cómo el kernel RBF soluciona el problema.

Teniendo puntos con el centro $\rightarrow$ clase -1 y el alrededor $\rightarrow$ clase +1 en 2D no se pueden separar con una línea pero el kernel RBF lo que hace es proyectarlos a otra dimensión y los convierte a separables y dibuja una frontera curva en lugar de una recta.

- Da un ejemplo real.
Detección de fraude en tarjeta, los datos no siguen una forma lineal y el comportamiento fraudulento puede ser complejo y con un kernel puede detectar patrones complejos y separar mejor los fraudes y los no fraudes.

~~7~~ = K-NN

• Ejercicio 8: Clasificación manual

Puntos:

clase A: (1,1), (2,2)

clase B: (4,4), (5,5)

Nuevo punto: (3,3)

- Clasifica con $K=1$
calculamos distancias al punto (3,3)

A:

(1,1) $\rightarrow$ lejos

(2,2) $\rightarrow$ distancia mas cercana

mas cercanos son (4,4) y (2,2)

con $K=2$ depende pero normalmente se toma el primero mas cercano
clasificación A

B:

(4,4) $\rightarrow$ misma que (2,2)

(5,5) $\rightarrow$ mas lejos

- con $K=3$
Tomamos los 3 mas cercanos

(2,2) $\rightarrow$ A

(4,4) $\rightarrow$ B

(1,1) $\rightarrow$ A

clasificación A

- ¿Que cambia?

con $K=1$ es muy sensible y puede dar errores o ruidos

con $K=3$ es mas estable, se basa en mayoría y es menos sensible a un solo punto.

con mayor K mas estabilidad hay.

Ejercicio 9: Es escalado de variables
Dataset con:

- Edad (0-100)
- Ingreso (0-1,000,000)

¿Qué problema hay en k-NN?

Que k-NN usa distancias y en ingresos tienen valores mucho más grandes que edad entonces, la distancia queda dominada por ingresos y edad no influyen la clasificación y el modelo se sesga hacia la variable con mayor escala.

¿Cómo solucionarlo?

Aplicamos escalado de variables

- Normalización (Min-Max)

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Llevando a los valores a un rango [0,1]

- Estandarización (Z-score)

$$X' = \frac{X - \mu}{\sigma}$$

media = 0

Desviación = 1

8- Naive Bayes

Ejercicio 10: Clasificación Probabilística
Dataset:

clase	P(A)	P(B)
Spam	0.6	0.7
No spam	0.2	0.3

Prior :

- Spam = 0.4

- No spam = 0.6

NUEVO

- contiene A y B

- P(Spam | datos)

$$P(\text{Spam} | A, B) \propto (P(A | \text{Spam}) \cdot P(B | \text{Spam}) \cdot P(\text{Spam}))$$

$$= 0.6 \cdot 0.7 \cdot 0.4 = 0.168 \text{ ó } 16.8\%$$

- P(No spam | datos)

$$P(\text{No spam} | A, B) \propto (P(A | \text{No spam}) \cdot P(B | \text{No spam}) \cdot P(\text{No spam}))$$

$$= 0.2 \cdot 0.3 \cdot 0.6 = 0.036 = 3.6\%$$

- Clasificar

Spam = 0.168

No spam = 0.036

ES SPAM

¿la independencia es real?

No siempre, Bayes asume que A y B son independientes en la vida real muchas variables están relacionadas por ejemplo palabras en un correo pueden estar conectadas entre sí pero aún así funciona en la práctica aunque la suposición no sea totalmente cierta.